


Datawarehouse Design



Na vandaag...

Weet/ken je...

Kan je...

Wanneer je dimensietabellen
horizontaal en/of verticaal
moet samenvoegen

Welk “meetwaarde-transport” je
moet uitvoeren om de
feittabellen juist in te vullen

Wat afgeleide dimensie- en
meetwaarden zijn en hoe je deze in
je Datawarehouse-ontwerp
modelleert.

Wat granulariteitsverschillen zijn

Uit welke onderdelen
ETL-schema's bestaan

De juiste dimensietabellen
aanbrengen en invullen in
Sterschema's

De juiste feittabellen
aanbrengen en invullen in
Sterschema's (inclusief
verbinding met dimensies)


Op 2 manieren
granulariteitsverschillen
afhandelen

Benodigde dataflows tussen
SDM's en DWH's inzichtelijk
maken in ETL-schema's

HC + WC



Recap: de datastraat vanaf hier




Source Data Model (SDM)

Denormalisering

Gedenormaliseerd

Gevisualiseerd

Het Data Warehouse (DWH)



Inmiddels is de structuur geschikt gemaakt voor analyse d.m.v. dimensioneel modelleren

Dit is het eindproduct: een datawarehouse op basis waarvan datadashboards gevuld kunnen worden


Je gaat van SDM naar DWH door SDM-tabellen horizontaal én verticaal samen te voegen.

Dimensietabellen verticaal samenvoegen

“Verticaal”: je zet van meerdere tabellen de rijen onder elkaar

Nieuwe dimensietabel: “datum”

Deze zit niet in operationele databases of SDM's, maar komt er in DWH's extra bij.





Deze klasse heeft een “order_date”

Deze klasse heeft een “bonus_date”



DWH, nu kan ik per datum alle activiteiten zien!

Dezelfde dimensies uit verschillende databases



Is de multipliciteit aan één kant 1?
Dan is verticaal samenvoegen niet nodig!


Is de multipliciteit aan beide kanten 0..1?
Dan moet je verticaal samenvoegen!

1. Laad van elke brontabel alle medewerkers in.
2. Houd alleen unieke medewerkers over: elke medewerker mag dus maar één keer voorkomen.

Dimensietabellen horizontaal samenvoegen

“Horizontaal”: je joint met meerdere tabellen.


Verschillende dimensies uit dezelfde database



DWH

CUSTOMER
-id
-fname
-lname
-address
-city
-state
-phone
-company_name
-state_id
-state_name
-region
-country

Dezelfde dimensies uit verschillende databases
die verschillende kolommen hebben




“birth_date”
komt alleen
hier voor

“sex” komt
alleen hier
voor

DWH,
“birth_date” &
“sex” moeten
hier allebei
voorkomen

aEMPLOYEE
-emp_id
-emp_fname
-emp_lname
-dept_id
-phone
-salary
-start_date
-birth_date
-sex

Afgeleide dimensiewaarden




Afgeleide dimensiewaarden zijn niet-numerieke kolommen die níét in het SDM voorkwamen, maar wel in het datawarehouse, ter bevordering van specifieke analyses.

In dit geval zijn medewerkers ingedeeld in “salary_groups” op basis van hun “salary”.

Voorbeeld:

- Salary > 10000 => “high”
- Salary <= 10000 =< “low”

DWH




Merk op dat alléén de salarisgroepen in de dimensietabel staan, niet de salarissen zelf.


Meetwaarden staan nóóit in dimensietabellen. Zometeen zullen we ze terugzien in de feittabellen.

Meetwaardetransport van dimensies naar feiten

SDM



DWH




Nogmaals: meetwaarden staan alléén in feittabellen.

Daarom moeten deze tijdens het ETL-proces gemigreerd worden van een dimensietabel naar feittabel.


Dit kan bijvoorbeeld met behulp van een SQL JOIN of een Python pandas merge.

Feitaggregatie




In SDM's kunnen feiten bestaan uit meerdere onderliggende feiten.

Bijvoorbeeld een bestelling ("SALES_ORDER") die meerdere bestelregels heeft ("SALES_ORDER_ITEM")



Feiten met een dergelijke hiërarchie moeten horizontaal samengevoegd worden tot één feittabel:
een geaggregeerd feit.

Afgeleide meetwaarden



Afgeleide meetwaarden zijn numerieke / berekenbare kolommen die níét in het SDM voorkwamen, maar wel in het datawarehouse, ter bevordering van specifieke analyses.

SALES_ORDER
<u>-id</u>
<u>-line_id</u>
-prod_id
-quantity
-unit_price
-turnover
-order_date
-cust_id
-sales_rep

turnover =
unit_price x quantity

Koppelingen tussen feiten in Datawarehouses

SALES_ORDER
<u>-id</u>
-line_id
-prod_id
-quantity
-unit_price
-turnover
-order_date
-cust_id
-sales_rep

BONUS
<u>-emp_id</u>
<u>-bonus_date</u>
-bonus_amount

Ik wil per datum álle bestellingen en álle gegeven bonussen kunnen zien!

Doe ik dit zo?!

Nee! Feittabellen worden nóóit met elkaar verbonden!

Indirecte koppelingen in Datawarehouses

SALES_ORDER
- <u>id</u>
- <u>line_id</u>
-prod_id
-quantity
-unit_price
-turnover
-order_date
-cust_id
-sales_rep

BONUS
- <u>emp_id</u>
- <u>bonus_date</u>
-bonus_amount

Ik wil per datum álle bestellingen en álle gegeven bonussen kunnen zien!


Hoe doe ik dit dan wél?!

Feittabellen indirect met elkaar laten verbinden via een dimensie!

De belangrijkste reden hiervoor is dat er zogeheten granulariteitsverschillen kunnen zijn.
Dit wil zeggen dat feiten niet altijd op hetzelfde detailniveau bijgehouden worden.

Stel dat we bijvoorbeeld bonussen niet per datum bijhouden, maar per maand.
Hoe komt ons Sterschema er dán uit te zien (volgende slide)?!

Granulariteitsverschillen



Tóch wil ik per maand alle feiten kunnen zien.

Hoe op te lossen?


2 manieren om granulariteitsverschillen op te lossen

Snowflaking

Snowflaking: het aanbrengen van associaties tussen dimensies in Sterschema's. Extra dimensie "MONTH" is aangemaakt.

Voordeel: je behoudt je data-integriteit. Je weet zeker dat alles naar elkaar herleid kan worden en dat er bijvoorbeeld geen "losse maanden" zijn.

Nadeel: je verlaagt je analysesnelheid, omdat er meerdere JOINS gemaakt moeten worden



Niet-snowflaking

Ook hier is een extra dimensie "MONTH" aangemaakt. Nu is er in sales_order "month_year" aangemaakt die wordt herleid uit "order_date"


Voordeel: je verhoogt je analysesnelheid, omdat er in minder tabellen gekeken hoeft te worden.

Nadeel: je loopt het risico dat uit datums de onjuiste maanden worden herleid. Als dit optreedt zou je data-integriteit in gevaar komen



Laatste stap: maak per dimensietabel een ETL-schema

ETL-schema's geven weer welke datastromen er nodig zijn om van SDM- naar DWH-tabellen te komen
Per dimensie- en feittabel moet een ETL-schema getekend worden.



Extract:

Data wordt uit het
SDM gehaald

Transform:


De nodige transformaties
worden uitgevoerd
(hier nog niet van toepassing)

Load:

De (eventueel
getransformeerde) data wordt
ingeladen in de DWH-tabel

Ietsje lastiger: 2 brontabellen horizontaal samenvoegen

In de dimensietabel Employee is data uit 2 operationele tabellen horizontaal samengevoegd: Employee & Department. Dergelijke samenvoegingen verdienen expliciet aandacht bij het modelleren en bouwen van ETL-processen.



- Fullname wordt gevuld op basis van emp_fname en emp_lname
- Uit salary worden zowel salary als Salary_group gevuld
- Hier moet je extra duidelijk maken op basis waarvan de 2 brontabellen worden samengevoegd

Nog lastiger: 2 brontabellen verticaal samenvoegen


In de dimensietabel DATE is data uit 2 brontabellen verticaal samengevoegd: Sales_Order & Bonus.
Ook zulke samenvoegingen verdienen expliciet aandacht bij het modelleren en bouwen van ETL-processen.

SALES_ORDER
<u>-id</u>
-order_date
-cust_id
-sales_rep

BONUS
<u>-emp_id</u>
-bonus_date
-bonus_amount

DATE
<u>date</u>
month
quarter
year

Verticale samenvoegingen in ETL-schema's



- Uit order_date en bonus_date worden met hulpfuncties allemaal datums gevuld. De namen van deze hulpfuncties moeten hierbij gezet worden.
- Hier moet je extra duidelijk maken op basis dat de 2 brontabellen verticaal worden samengevoegd (recap: JOIN -> horizontaal, UNION -> verticaal).

Na vandaag...

Weet/ken je...

Kan je...

Wanneer je dimensietabellen
horizontaal en/of verticaal
moet samenvoegen

De juiste dimensietabellen
aanbrengen en invullen in
Sterschema's

Welk "meetwaarde-transport" je
moet uitvoeren om de
feittabellen juist in te vullen

Wat afgeleide dimensie- en
meetwaarden zijn en hoe je deze in
je Datawarehouse-ontwerp
modelleert.

De juiste feittabellen
aanbrengen en invullen in
Sterschema's (inclusief
verbinding met dimensies)

Wat granulariteitsverschillen zijn

Op 2 manieren
granulariteitsverschillen
afhandelen

Uit welke onderdelen
ETL-schema's bestaan

Benodigde dataflows tussen
SDM's en DWH's inzichtelijk
maken in ETL-schema's

HC + WC

