


Clusteringmodellen in (unsupervised) Machine Learning



Na vandaag...

Weet je...

Kan je...

Wat het precieze verschil is
tussen classificatie en
clustering

Wat de voor- en nadelen van
clustering zijn t.o.v. classificatie
en andersom

Welke verschillende
clustermethoden er zijn

Welke stappen een k-
meansclustermodel volgt.

Een k-meansclustermodel
maken


De juiste k bepalen door middel
van het berekenen van de
inter- en **intra**clusterafstand.

HC +
practicum



Classificatie vs. Clustering


Classificatie



Classificatie is het onderbrengen van een *praktijksituatie / individu* in een bepaalde *klasse*

De klassen zijn hier dus al bekend en we willen dat het model per datapunt op dezelfde klasse uitkomt

Clustering



Clustering is het vinden / bepalen van klassen in data.

De klassen zijn hier dus nog onbekend en we willen dat ons model deze zelf gaat vinden/maken, *zonder menselijke input door enkel het algoritme.*

Voor-/nadeel van clustering t.o.v. classificatie

	Clustering	Classificatie
Voordeel t.o.v. de ander	Creatief: het model vormt clusters die wij als mens moeilijk zouden kunnen bedenken.	Resultaten makkelijk meetbaar: je weet immers de juiste klasse al en kan die vergelijken met de voorspelde klasse.
Nadeel t.o.v. de ander	De gevormde clusters kunnen toevallig en niet op waarheid gebaseerd zijn: “horen datapunten A en B wel écht bij elkaar?”	Niet creatief: er worden alleen waarden van afhankelijke variabelen voorspeld die al bestaan.

Toepassingen van clustering


Overall waar labels / klassen onbekend, onzeker of te duur zijn.

- **Marketing:** groepen van zelfde soort klanten
- **Sterrenkunde:** groepen van zelfde soort sterren / zonnestelsels
- **DNA onderzoek:** groepen genen met gelijksoortig effect.
- **ChatGPT:** alle woorddelen zijn geclusterd in een supergrote hoeveelheid dimensies om betekenis aan woorden en zinnen te kunnen verlenen.




Verskillende clustermethoden

Overlapping vs. non-overlapping



- Non-overlapping: een datapunt kan bij slechts één cluster horen.
- Overlapping: een datapunt kan bij meerdere clusters horen


Top-down vs. bottom-up



- Top-down: eerst komen alle datapunten in één groot cluster terecht. Vervolgens wordt dat grote cluster opgedeeld in meerdere kleinere.
- Bottom-up: elk datapunt krijgt eerst zijn eigen cluster en vervolgens wordt er gemerged met dichtstbijzijnde clusters.


K-meansclustering: de stappen

Stap 1: Kies 3 willekeurige punten: dit zijn de “startcentra” van de clusters



K-meansclustering: de stappen

Stap 2: Koppel elk punt aan het dichtstbijzijnde centrum




Voor deze koppeling wordt per datapunt de zgn. "euclidische afstand" berekend tot elk centrum.

Vervolgens wordt elk punt gekoppeld aan het centrum waarbij de euclidische afstand het laagst is.


K-meansclustering: de stappen

Stap 3: Verplaats het centrum naar het daadwerkelijke centrum van het cluster



K-meansclustering: de stappen


Stap 4: Zet alle punten opnieuw bij het dichtstbijzijnde centrum



K-meansclustering: de stappen


Stap 5: Herhaal stappen 3 en 4 totdat de centra bijna niet meer verplaatsen.

“Hoe zie ik dit?” De euclidische afstand ontwikkelt zich bijna niet meer.



Hoe kies ik het aantal clusters (de zogenoemde k)?

Je bouwt de eerste versie van je clustermodel altijd met een willekeurig aantal clusters (k). Vervolgens evalueer je de clusterkwaliteit met de interclusterafstand en de intraclusterafstand. Op basis hiervan kan je je k verhogen of juist verlagen



3 meetwaarden:

- **Inter**clusterafstand: de afstand tussen clusters.
- **Intra**clusterafstand: de afstand tussen punten binnen een cluster.
- De **silhouettescore**:
$$\frac{\text{interclusterafstand} - \text{intraclusterafstand}}{\max(\text{interclusterafstand}, \text{intraclusterafstand})}$$


Advies

Experimenteer met meerdere k's. Je bijgestelde k is een verbetering als...

- De **inter**clusterafstand verhoogd is.
- De **intra**clusterafstand verlaagd is.
- De **silhouettescore** verhoogd is.

Inzoomen op de intracusterafstand met de elleboogmethode

De elleboogmethode visualiseert per clusteraantal wat de intracusterafstand is. Op basis hiervan kan het optimale aantal clusters, de zogeheten k-waarde, dus bepaald worden.



De **WSS Error (Within-Cluster Sum of Squares Error)** is een mogelijke maatstaf voor de intracusterafstand.

Het kwadrateert per punt de afstand tot het eigen centrum en telt deze kwadraten bij elkaar op.

Elke ruimtelijke afwijking t.o.v. het eigen centrum wordt hier als "error" gezien.

In een dergelijke curve vind je het optimale aantal clusters door het punt te zoeken waar de curve afvlakt.

Je kijkt niét naar het laagste punt, omdat je dan het risico hebt dat je teveel clusters aanmaakt.

Verskillende clustering- en classificatiemethoden

Soort model	Model	Globale werking
Classificatie	Decision Trees	Datastructuur waarin elk knooppunt staat voor een beslissing
	Random Forests	Combineert meerdere Decision Trees om nauwkeuriger voorspellingen te doen
	Logistische Regressie	Modelleert de waarschijnlijkheid van uitkomsten. Continue regressie-uitkomsten worden naar discrete omgezet: “er is een kans van 65% dat er een kat op deze foto staat, dus er staat een kat op deze foto”.
Clustering	K-Means Clustering	Verdeelt gegevens t.o.v. centra en optimaliseert vervolgens op iteratieve wijze de locatie van die centra
	Hiërarchische Clustering	Creëert clusterhiërarchieën door punten samen te voegen op basis van hun inter- en intraclusterafstand
	DBSCAN	Vormt clusters op basis van datadichtheid: aantallen datapunten. Scheidingen van clusters worden correct aangegeven met gebieden met een lage datadichtheid.

Demo time



Na vandaag...

Weet je...

Kan je...

Wat het precieze verschil is
tussen classificatie en
clustering

Wat de voor- en nadelen van
clustering zijn t.o.v. classificatie
en andersom

Welke verschillende
clustermethoden er zijn

Welke stappen een k-
meansclustermodel volgt.

Een k-meansclustermodel
maken

De juiste k bepalen door middel
van het berekenen van de
inter- en **intra**clusterafstand.

HC +
practicum

