


Classificatiemodellen in Machine Learning



Na vandaag...

Weet je...

Wat de gini impurity is en hoe DecisionTree-algoritmen deze gebruiken om beslisbomen te trainen.

Uit welke onderdelen Decision Trees bestaan

Wat under- en overfitting is en hoe je dit kan herkennen bij het evalueren van classificatiemodellen

Wat een confusion matrix is en hoe je deze moet lezen bij het evalueren van classificatiemodellen

Kan je...

Supervised classificatiemodellen trainen en testbaar maken.

Verantwoorden hoe een Decision Tree is opgebouwd, o.a. d.m.v. het geven van impurity-berekeningen.

Reeds gemaakte Decision Trees lezen en verbetermogelijkheden bepalen

De uitkomsten van classificatiemodellen interpreteren en evalueren met behulp van 4 meetwaarden

HC + WC



De gini impurity met 2 mogelijke targetwaarden

Een bepaalde “dataset” bestaat uit 10 bekers, waarvan 7 rode en 3 groene.
“kleur” is de target / afhankelijke variabele



De kans dat iemand één rode beker pakt is $(7/10)$.

De kans dat iemand twee rode bekers pakt is $(7/10) \times (7/10)$.

Hierbij wordt ervan uitgegaan dat elke getrokken beker weer teruggaat in de “dataset”.

De kans dat iemand één groene beker pakt is $(3/10)$.

De kans dat iemand met terugleggen twee groene bekers pakt is $(3/10) \times (3/10)$.

Ook hiérbij wordt ervan uitgegaan dat elke getrokken beker weer teruggaat in de “dataset”.

De kans dat iemand twee bekers pakt van dezelfde kleur is $(7/10)^2 + (3/10)^2$

De kans dat iemand twee bekers pakt van een verschillende kleur is $1 - (7/10)^2 - (3/10)^2$

Dit is de gini impurity: de kans dat je met terugleggen 2 items uit je dataset kiest met verschillende targetwaarden

De gini impurity met meer dan 2 mogelijke targetwaarden

Een bepaalde “dataset” bestaat uit 10 bekers, waarvan 5 rode, 2 blauwe en 3 groene.
“kleur” is nog steeds de target / afhankelijke variabele



De kans dat iemand twee rode bekers pakt is
 $(5/10)^2$

De kans dat iemand twee blauwe bekers pakt is
 $(2/10)^2$

De kans dat iemand twee groene bekers pakt is
 $(3/10)^2$

De kans dat iemand twee bekers pakt van dezelfde kleur is
 $(5/10)^2 + (2/10)^2 + (3/10)^2$

De kans dat iemand twee bekers pakt van een verschillende kleur is
 $1 - (5/10)^2 - (2/10)^2 - (3/10)^2$

Dit is de gini impurity: de kans dat je met terugleggen 2 items uit je dataset kiest met verschillende targetwaarden

Als je de kans wil berekenen dat 2 gebeurtenissen samen (achter elkaar) voorkomen, vermenigvuldig je beide onderliggende kansen.

Als je de kans wil berekenen dat óf de ene óf de andere gebeurtenis voorkomt, tel je de onderliggende kansen op

De gini impurity met allemaal unieke targetwaarden

Een bepaalde “dataset” bestaat uit 10 bekers, die allemaal een andere kleur hebben.
“kleur” is nog steeds de afhankelijke variabele



Enzovoort

De kans dat iemand twee rode bekers pakt is
 $(1/10)^2$

De kans dat iemand twee bekers pakt van dezelfde kleur is
 $(1/10)^2 \times 10$

Omdat er sprake is van pakken met terugleggen (elke getrokken beker gaat terug in de dataset), is er bijna altijd een kans dat je 2 bekers van dezelfde kleur pakt.

De kans dat iemand twee blauwe bekers pakt is
 $(1/10)^2$

De kans dat iemand twee bekers pakt van een verschillende kleur is
 $1 - ((1/10)^2 \times 10)$

Hierom is de gini impurity bijna altijd hoger dan, en bijna nooit exact of kleiner dan, 0.

Dit geldt voor alle tien mogelijke kleuren

De gini impurity met slechts 1 targetwaarde

Een bepaalde “dataset” bestaat uit 10 bekers, deze zijn allemaal rood.
“kleur” is nog steeds de afhankelijke variabele



De kans dat iemand twee rode
bekers pakt is
 $(10/10)^2 = 1$

De kans dat iemand twee bekers pakt
van dezelfde kleur is
 $(10/10)^2 = 1$

De kans dat iemand twee bekers pakt
van een verschillende kleur is $1 -$
 $(10/10)^2 = 0$

Bij een dataset waar alle items
dezelfde targetwaarde hebben, is de
gini impurity dus altijd 0.

De gini impurity kan dus 1 zijn,
maar is bijna nooit exact gelijk
aan 0


De gini impurity in het DecisionTree-algoritme

Titanic-dataset

Passenger	Sex	Pclass	Age	Survived (target)
A	Male	3	22	0
B	Female	3	26	1
C	Male	1	35	0
D	Female	1	30	1

In de “root” van elke stump komt de splitsvoorwaarde te staan. Deze heeft altijd betrekking op een feature

Elke “leaf” bevat een subset van de data als gevolg van de splitsing door de “root”



De gini impurity van deze totale stump wordt als volgt berekend:

- Vermenigvuldig voor elke leaf het gewicht en de impurity
- Tel al deze vermenigvuldigingen bij elkaar op.

De gini impurity van deze dataset is
 $1 - (2/4)^2 - (2/4)^2 = 0,50$

Het DecisionTree-algoritme probeert deze gini impurity te verminderen door het maken van “stumps”: kleine beslisboompjes die de dataset onderverdelen volgens slechts één splitsvoorwaarde

Per leaf zijn er 2 meetwaarden belangrijk:

- Gewicht: hoeveel procent van de originele datapunten in de leaf gekomen is.
- Impurity: de kans dat je binnen het blad 2 items pakt die dezelfde targetvariabele hebben.

De eerste stump: “sex”

Titanic-dataset

Passenger	Sex	Pclass	Age	Survived (target)
A	Male	3	22	0
B	Female	3	26	1
C	Male	1	35	0
D	Female	1	30	1


De gini impurity van deze dataset is

$$1 - (2/4)^2 - (2/4)^2 = 0,50$$

Het DecisionTree-algoritme probeert deze gini impurity te verminderen door het maken van “stumps”: kleine beslisboompjes die de dataset onderverdelen volgens slechts één splitsvoorwaarde

Totaal aantal items: 4
Aantal female: 2
Gewicht_female: (2/4)

Kans op 2 survived: $(2/2)^2$
Kans op 2 dead: $(0/2)^2$
Impurity_female:
 $1 - (2/2)^2 - (0/2)^2 = 0$



Totaal aantal items: 4
Aantal male: 2
Gewicht_male: (2/4)

Kans op 2 survived: $(0/2)^2$
Kans op 2 dead: $(2/2)^2$
Impurity_male:
 $1 - (2/2)^2 - (0/2)^2 = 0$

De gini impurity van deze totale stump is

$$\text{Gewicht_female} \times \text{Impurity_female} + \text{Gewicht_male} \times \text{Impurity_male} = \\ (2/4) \times 0 + (2/4) \times 0 = 0$$

De tweede stump: “age” i.p.v. “sex”

Titanic-dataset

Passenger	Sex	Pclass	Age	Survived (target)
A	Male	3	22	0
B	Female	3	26	1
C	Male	1	35	0
D	Female	1	30	1

De gini impurity van deze dataset is
 $1 - (2/4)^2 - (2/4)^2 = 0,50$

Het DecisionTree-algoritme probeert deze gini impurity te verminderen door het maken van “stumps”: kleine beslisboompjes die de dataset onderverdelen volgens slechts één criterium

Totaal aantal items: 4

Aantal < 28: 2


Gewicht_under_28: (2/4)

Kans op 2 survived: $(1/2)^2$

Kans op 2 dead: $(1/2)^2$

Impurity_under_28:

$1 - (1/2)^2 - (1/2)^2 = 0,5$



Totaal aantal items: 4

Aantal >= 28: 2

Gewicht_at_least_28: (2/4)

Kans op 2 survived: $(1/2)^2$

Kans op 2 dead: $(1/2)^2$

Impurity_at_least_28:

$1 - (1/2)^2 - (1/2)^2 = 0,5$

De gini impurity van deze totale stump is

Gewicht_female x Impurity_female + Gewicht_male x Impurity_male =
 $(2/4) \times 0,5 + (2/4) \times 0,5 = 0,5$

De derde stump: een andere grens voor “age”

Titanic-dataset

Passenger	Sex	Pclass	Age	Survived (target)
A	Male	3	22	0
B	Female	3	26	1
C	Male	1	35	0
D	Female	1	30	1

De gini impurity van deze dataset is
 $1 - (2/4)^2 - (2/4)^2 = 0,50$

Het DecisionTree-algoritme probeert deze gini impurity te verminderen door het maken van “stumps”: kleine beslisboompjes die de dataset onderverdelen volgens slechts één criterium

Totaal aantal items: 4

Aantal < 33: 3


Gewicht_under_33: (3/4)

Kans op 2 survived: $(2/3)^2$

Kans op 2 dead: $(1/3)^2$

Impurity_under_28:

$1 - (2/3)^2 - (1/3)^2 = 0,44$



Totaal aantal items: 4

Aantal >= 33: 1

Gewicht_at_least_33: (1/4)

Kans op 2 survived: $(0/1)^2$

Kans op 2 dead: $(1/1)^2$

Impurity_at_least_33:

$1 - (0/1)^2 - (1/1)^2 = 0$

De gini impurity van deze totale stump is


Gewicht_female x Impurity_female + Gewicht_male x Impurity_male =
 $(3/4) \times 0,44 + (1/4) \times 0 = 0,33$

Welke stump is de “winnaar”?

Initiële split Impurity: 0,5


Passenger	Sex	Pclass	Age	Survived (target)
A	Male	3	22	0
B	Female	3	26	1
C	Male	1	35	0
D	Female	1	30	1

Split Impurity: 0,5




De stump met de laagste impurity wordt aan de uiteindelijke beslisboom toegevoegd!

Split Impurity: 0




Split Impurity: 0,33



Beslisbomen lezen

Stel: vrouw A is aan boord van de Titanic gegaan met een ticket voor de 1^e klasse...



De linkerpijl staat altijd voor True, de rechterpijl voor False.


Het eerste getal tussen blokhaken staat voor survived = 0, het tweede getal voor survived = 1

Er waren 139 niet-3^e-klasse-vrouwen aan boord
Daarvan hebben er 6 de ramp niet overleefd en 133 wel.
Conclusie: vrouw A heeft de ramp waarschijnlijk wel overleefd

Voor 3^e-klasse-vrouwen kan een minder
sluitende conclusie worden getrokken
(iets minder dan 50% overlevingskans).

“Hoe diep wordt mijn boom?”


Underfitting: max_depth = 2



Voor 3^e-klasse-vrouwen kan een minder sluitende conclusie worden getrokken (ong. 50% overlevingskans).

De beslisboom leert té weinig van de traindata, er wordt onvoldoende gekeken naar de invloed van onafhankelijke variabelen!


Overfitting: max_depth is niet ingegeven (in de onderste leafs is de impurity exact 0)



De beslisboom leert teveel van de traindata, waardoor het model niet te generaliseren is naar nieuwe/toekomstige data.

Classificatiemodellen evalueren met een Confusion Matrix

De term “Positive” komt altijd met een stempel. In dit geval: “heeft ramp overleefd”.
De term “Negative” staat voor het tegenovergestelde hiervan. In dit geval: “heeft ramp niet overleefd”




4 direct zichtbare getallen:

- True Positives: correct voorspeld dat iemand een stempel heeft.
- True Negatives: correct voorspeld dat iemand géén stempel heeft.
- False Positives: voorspeld dat iemand een stempel heeft, terwijl dat in werkelijkheid niet zo is. Synoniem: “type I error”.
- False Negatives: voorspeld dat iemand géén stempel heeft, terwijl dat in werkelijkheid wel zo is. Synoniem: “type II error”.

Classificatiemodellen evalueren met een Confusion Matrix

De term “Positive” komt altijd met een stempel. In dit geval: “heeft ramp overleefd”.
De term “Negative” staat voor het tegenovergestelde hiervan. In dit geval: “heeft ramp niet overleefd”



- Accuracy: de procentuele mate waarin het model goede voorspellingen heeft gemaakt.
 - Formule: $TP + TN / (TP + TN + FP + FN)$
- Recall: de procentuele mate waarin het model échte positieve gevallen als “positief” classificeert.
 - Formule: $TP / (TP + FN)$
- Precision: welk deel van de als positief voorspelde gevallen ook écht positief is.
 - Formule: $TP / (TP + FP)$

Meetwaarden

- Accuracy: 77%
- Recall: 51%
- Precision: 88%

De berekeningen hiervan staan in de Speaker Notes

Precision vs. recall

$$\text{Precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

Hoe hoger de precision, hoe voorzichtiger het model classificeert.

“Voorspel alléén iets als je bijna zeker weet dat die voorspelling klopt”



$$\text{Recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$

Hoe hoger de recall, hoe ruimer het model classificeert.

“Probeer alle positieve gevallen te vinden, het geeft niet als een aantal voorspellingen fout is”.



De confusion matrix met ongebalanceerde datasets

De dataset die wordt gerepresenteerd door deze confusion matrix is heel erg ongebalanceerd. Er zijn namelijk veel meer mensen die **niet** ziek zijn (910) dan mensen die **wél** ziek zijn (90)

Casus Ziekenhuis:

Is iemand ziek (true) of niet (false)?

	Voorspeld: true	Voorspeld: false
Werkelijk: true	40	50
Werkelijk: false	10	900


Meetwaarden

- Accuracy: 94%
- **Recall: 44%**
- Precision: 80%

Welke fout is erger (ethische afweging)?

- Dat er af en toe iemand als “gezond” wordt geclassificeerd, terwijl diegene ziek is?
 - Dit zijn de False Negatives
 - De recall is belangrijker dan de precision
- Dat er af en toe iemand als “ziek” wordt geclassificeerd, terwijl diegene gezond is?
 - Dit zijn de False Positives
 - De precision is belangrijker dan de recall

De berekeningen hiervan staan in de Speaker Notes



Conclusie

Weliswaar is de accuracy heel hoog, maar de recall is heel laag.

Het model presteert minder goed dan de accuracy weergeeft!

Een andere ongebalanceerde casus: Rechtbank

De dataset die wordt gerepresenteerd door deze confusion matrix is heel erg ongebalanceerd. Er zijn namelijk veel meer mensen die onschuldig zijn (950) dan mensen die wél schuldig zijn (50)

Casus Rechtbank:

Is iemand schuldig (true) of niet (false)?

	Voorspeld: true	Voorspeld: false
Werkelijk: true	40	10
Werkelijk: false	50	900


Meetwaarden

- Accuracy: 94%
- Recall: 80%
- **Precision: 44%**

De berekeningen hiervan staan in de Speaker Notes

Welke fout is erger (ethische afweging)?

- Dat er af en toe iemand als “onschuldig” wordt geclassificeerd, terwijl diegene schuldig is?
 - Dit zijn de False Negatives
 - De recall is belangrijker dan de precision
- Dat er af en toe iemand als “schuldig” wordt geclassificeerd, terwijl diegene onschuldig is?
 - Dit zijn de False Positives
 - De precision is belangrijker dan de recall



Conclusie

Weliswaar is de accuracy heel hoog, maar de precision is heel laag.

Het model presteert minder goed dan de accuracy weergeeft!

Confusion matrices: 2x2 vs. 3x3

2x2

Bij slechts 2 labels. In dit geval: “0” en “1”.
Synoniem: “binaire classificatie”

	Voorspeld: true	Voorspeld: false
Werkelijk: true	40	10
Werkelijk: false	50	900

- Slechts 1 accuracy
- Slechts 1 precision
- Slechts 1 recall

Zie Speaker Notes voor berekeningen

3x3

Bij meer dan 2 labels. In dit geval: “0”, “1” en “2”.
Synoniem: “multi-class classificatie”

	Voorspeld: 0	Voorspeld: 1	Voorspeld: 2
Werkelijk: 0	40	10	50
Werkelijk: 1	50	900	40
Werkelijk: 2	10	20	30

- Slechts 1 accuracy
- 3 precisions (1 voor elk label)
- 3 recalls (1 voor elk label)

Zie Speaker Notes voor berekeningen

Demo time



Na vandaag...

Weet je...

Wat de gini impurity is en hoe DecisionTree-algoritmen deze gebruiken om beslisbomen te trainen.

Uit welke onderdelen Decision Trees bestaan

Hoe je under- en overfitting kan herkennen bij het evalueren van classificatiemodellen

Wat een confusion matrix is en hoe je deze moet lezen bij het evalueren van classificatiemodellen

Kan je...

Supervised classificatiemodellen trainen en testbaar maken.

Verantwoorden hoe een Decision Tree is opgebouwd, o.a. d.m.v. het geven van impurity-berekeningen.

Reeds gemaakte Decision Trees lezen en verbetermogelijkheden bepalen

De uitkomsten van classificatiemodellen interpreteren en evalueren met behulp van 4 meetwaarden

HC + WC

