

Regressiemodellen in Machine Learning



Na vandaag...

Weet je...

Wat het verschil is tussen Machine Learning en “traditionele AI”

Wat het verschil is tussen supervised & unsupervised Machine Learning

Welke supervised modellen er zijn en wanneer je welke gebruikt.

Hoe het lineaire-regressiealgoritme werkt

Kan je...

Datasets prepareren voor het toepassen van Machine-Learningmodellen

Supervised regressiemodellen train- en testbaar maken.


De uitkomsten van regressiemodellen interpreteren en evalueren

HC + WC




Machine Learning vs. “Traditionele AI”

Traditionele AI



In een bepaalde setting werd voor elk denkbaar scenario een regel/algorithm geprogrammeerd, waarmee computers tot de juiste / meest optimale antwoorden kwamen.


Machine Learning



We laten computers zelf denken door hen inputs en antwoorden mee te geven en vervolgens te zeggen: “bepaal zelf maar met welke regels je van inputs tot de juiste outputs komt”.

Soorten Machine-Learningmodellen (1)

De voorspellingen van modellen kunnen gecontroleerd worden



Machine Learning

Je vraagt je modellen zélf op zoek te gaan naar patronen in de data, zonder menselijke input. Er zijn geen “juiste antwoorden”.

Supervised Learning Algorithms

Regression

Classification

Unsupervised Learning Algorithms

Clustering

Association

Soorten Machine-Learningmodellen (2)

Doel: het produceren van voorspellingen die zoveel mogelijk overeenkomen met de werkelijkheid


Supervised (deze en volgende les)

Heeft <passagier>
de ramp met de
Titanic overleefd?



Juist
wel!

Nee




Unsupervised

Kan je mijn 6
klanten opdelen
in 2 groepen?



Oke... als jij het
zegt... ;-)

Klanten 1, 3 en 4
vormen een
groep en klanten
2, 5 en 6 ook



Soorten Supervised Machine-Learningmodellen

Regressiemodellen (vandaag)

Als je continue data wilt voorspellen

- Continue data: getallen die “tussenwaarden” kunnen hebben (bijvoorbeeld X,1; X,5; X,9; enzovoort). Bijvoorbeeld lengte, gewicht en/of temperatuur

Classificatiemodellen (volgende AI-les)

Als je categorische of discrete data wilt voorspellen

- Categorische data: niet-numerieke data. Bijvoorbeeld geslacht of burgerlijke staat.
- Discrete data: numerieke data, maar decimale tussenwaarden zijn niet mogelijk. Dit zijn getalsmatige categorieën (bijv. 1 of 2, maar niet 2,5). Bijvoorbeeld “ratings” van 1 t/m 5

PassengerId	Pclass	Name	Sex	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	Age
1	3	Braund; M	male	1	0	A/5 21171	7.25		S	0	22
2	1	Cumings; J	female	1	0	PC 17599	712.833	C85	C	1	38
3	3	Heikkinen; S	female	0	0	STON/O2.	7.925		S	1	26
4	1	Futrelle; M	female	1	0	113803	53.1	C123	S	1	35
5	3	Allen; Mr. W	male	0	0	373450	8.05		S	0	35
6	3	Moran; Mr. R	male	0	0	330877	84.583		Q	0	36

Age is continu

Iemand kan bijvoorbeeld 22,5; 38,5; enzovoort jaar oud zijn.

Ticket is categorisch

Hier zijn namelijk (deels) geen getallen ingevuld!

Survived is discreet

Je kan hier alleen de getallen 0 en 1 invullen! Getallen als 0,5; 0,2 enzovoort zijn hier dus niet mogelijk.

Onafhankelijke en afhankelijke variabelen

De afhankelijke variabele (target) is datgene wat je wilt voorspellen op basis van de onafhankelijke variabelen (features)
Voorbeeld leeftijdsvoorspeller (vandaag):

PassengerId	Pclass	Name	Sex	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	Age
1	3	Braund; M	male	1	0	A/5 21171	7.25		S	0	22
2	1	Cumings; I	female	1	0	PC 17599	712.833	C85	C	1	38
3	3	Heikkinen; f	female	0	0	STON/O2.	7.925		S	1	26
4	1	Futrelle; M	female	1	0	113803	53.1	C123	S	1	35
5	3	Allen; Mr. V	male	0	0	373450	8.05		S	0	35
6	3	Moran; Mr.	male	0	0	330877	84.583		Q	0	36


Voorbeeld survived-voorspeller (volgende AI-les):

PassengerId	Pclass	Name	Sex	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived	Age
1	3	Braund; M	male	1	0	A/5 21171	7.25		S	0	22
2	1	Cumings; I	female	1	0	PC 17599	712.833	C85	C	1	38
3	3	Heikkinen; f	female	0	0	STON/O2.	7.925		S	1	26
4	1	Futrelle; M	female	1	0	113803	53.1	C123	S	1	35
5	3	Allen; Mr. V	male	0	0	373450	8.05		S	0	35
6	3	Moran; Mr.	male	0	0	330877	84.583		Q	0	36

Het afhandelen van niet-numerieke onafhankelijke variabelen

In regressiemodellen moeten onafhankelijke variabelen numeriek zijn!
Met one-hot encoding kun je categorische variabelen naar numerieke omzetten.

	Name	Pclass	Sex	Fare	Age
0	Braund; Mr. Owen Harris	3	male	7.25	22
1	Cumings; Mrs. John Bradley (Florence Briggs Th...	1	female	712.833	38
2	Heikkinen; Miss. Laina	3	female	7.925	26
3	Futrelle; Mrs. Jacques Heath (Lily May Peel)	1	female	53.1	35
4	Allen; Mr. William Henry	3	male	8.05	35
...	...	...	...	...	...
886	Montvila; Rev. Juozas	2	male	13	27
887	Graham; Miss. Margaret Edith	1	female	30	19
888	Johnston; Miss. Catherine Helen "Carrie"	3	female	23.45	15
889	Behr; Mr. Karl Howell	1	male	30	26
890	Dooley; Mr. Patrick	3	male	7.75	32



One-hot encoding

Per mogelijke waarde van een niet-numerieke kolom ontstaat een extra wel-numerieke kolom.

False & True refereren automatisch naar 0 en 1

	female	male
0	False	True
1	True	False
2	True	False
3	True	False
4	False	True
...	...	...
886	False	True
887	True	False
888	True	False
889	False	True
890	False	True

Let op: verwijder kolommen waarvan de waarde per rij verschilt (bijv. 'Name'), i.p.v. deze te one-hot encoden. Anders krijg je namelijk enorm veel extra kolommen die amper extra voorspellende waarde hebben.

De train- en de testset

Alle rijen uit een bepaalde dataset worden onderverdeeld in een trainset (ong. 85%) en een testset (ong. 15%)

Trainset

	Pclass	Fare	female	male	Age
0	3	7.25	False	True	22
1	1	712.833	True	False	38
2	3	7.925	True	False	26
3	1	53.1	True	False	35
4	3	8.05	False	True	35
5	3	84.583	False	True	36
6	1	518.625	False	True	54
7	3	21.075	False	True	2
8	3	111.333	True	False	27
9	2	300.708	True	False	14

Bij het maken/trainen van een leeftijdsvoorspeller geven we ons regressiemodel de trainset mee, zodat patronen gevonden kunnen worden.

Testset

Hoe dicht liggen de voorspellingen bij de realiteit?

	Pclass	Fare	female	male	Age	Predicted_Age
11	1	26.55	True	False	58	61.0
12	3	8.05	False	True	20	47.0
13	3	31.275	False	True	39	46.0
14	3	78.542	True	False	14	42.0
15	2	16	True	False	55	20.0
16	3	29.125	False	True	2	46.0
17	2	13	False	True	36	50.0
18	3	18	True	False	31	62.0
19	3	7.225	True	False	36	20.0

Het splitsproces

We willen onze dataset opsplitsen in een train- en een testset.

- De trainset (ongeveer 85%): wordt gebruikt om het model te trainen: datapatronen te laten herkennen.
- De testset (ongeveer 15%): wordt gebruikt als “zogenaamd” nieuwe data om modelprestaties te meten.

	Pclass	Fare	female	male	Age
0	3	7.25	False	True	22
1	1	712.833	True	False	38
2	3	7.925	True	False	26
3	1	53.1	True	False	35
4	3	8.05	False	True	35
...	...	...	...	...	...
886	2	13	False	True	27
887	1	30	True	False	19
888	3	23.45	True	False	15
889	1	30	False	True	26
890	3	7.75	False	True	32

We willen de waarde van “Age” bepalen: dit is onze afhankelijke variabele. Elke overige kolom is een onafhankelijke variabele.

Het splitsproces

X_{train}

- X staat voor alle kolommen die onafhankelijke variabelen bevatten.
- y staat voor de kolom waarin de afhankelijke (te voorspellen) variabele zit.

y_{train}

X_{test}

y_{test}

De werking van regressie

Het lineaire-regressie-algoritme probeert een rechte lijn te tekenen die (ongeveer) door alle te voorspellen datapunten heenloopt.

De formule van de lijn is:

$$y = a * X + b$$

a heet ook wel de 'slope'


b heet ook wel de 'intercept'

2 bewegingen die de lijn kan maken:

- Als a verandert **roteert de lijn**.
 - Groter: naar links (steiler)
 - Kleiner: naar rechts (vlakker)
- Als b verandert **verschuift de lijn**.
 - Groter: naar boven
 - Onder: naar beneden.

In dit geval is er 1 onafhankelijke variabele en 1 afhankelijke variabele.

2 variabelen in totaal: een zogenoemde **bivariate analyse**




(Voor) de eerste regressie-iteratie

Voordat je het algoritme toepast, stel je het volgende in:

- Het aantal trainingsiteraties, ook wel epochs genoemd
- De learning_rate: een getal tussen 0 en 1. In dit geval: 0,01

In de eerste iteratie...

- Wordt er een willekeurige regressielijn getekend.
 - In dit geval is de formule: $y = 0,5X + 0,2$
- Wordt er een willekeurig datapunt uitgekozen waar de lijn zich naartoe moet bewegen
- Op basis hiervan roteert de lijn
 - De nieuwe a moet groter worden, want de lijn moet steiler worden.
 - De learning rate zorgt voor een verhoging van de huidige a.
 - Nieuwe a: $0,5 \times (0,01 + 1) = 0,505$
- Op basis hiervan verschuift de lijn
 - De nieuwe b moet groter worden, want de lijn moet omhoog
 - De learning rate zorgt voor een verhoging van de huidige b
 - Nieuwe b: $0,2 \times (0,01 + 1) = 0,202$



Volgende epochs

De **nieuwe lijn** is ietsje verbeterd t.o.v. de oude lijn.


Oude formule: $y = 0,5X + 0,2$

Nieuwe formule: $y = 0,505X$ (steiler) + 0,202 (hoger)

In elke volgende iteratie...

- Wordt er wéér een willekeurig datapunt uitgekozen waar de lijn zich naartoe moet bewegen
- Op basis hiervan moet de lijn weer roteren:
 - A plus learning rate als deze steiler moet worden
 - A min learning rate als deze vlakker moet worden
- Ook moet de lijn weer verschuiven:
 - b plus learning rate als deze omhoog moet
 - b min learning rate als deze omlaag moet

Dit proces van het wijzigen van a en b gaat zo door, totdat het vooraf ingestelde aantal iteraties/epochs bereikt is.



Pas op met je learning rate!

De learning_rate is een getal tussen 0 en 1 dat bepaalt in welke mate a en b gewijzigd worden per epoch.

“Moet mijn learning rate dan niet ‘gewoon’ zo hoog mogelijk zijn?”


Nee!

Op deze manier past de lineaire regressielijn zichzelf namelijk telkens veel te sterk aan, waardoor het om het optimum heen blijft cirkelen, maar deze nooit bereikt.

Leren in Machine Learning vindt altijd plaats in kleine stapjes, zodat er geen optimum over het hoofd gezien wordt.

Raar, maar waar:

“Een hoge learning rate heeft als risico dat je model weinig leert”




Bivariate en multivariate analyse

Bivariate analyse

Als er in totaal 2 variabelen zijn, 1 feature en 1 target, is er sprake van een bivariate analyse.

Deze kan gevisualiseerd worden in een 2D-tekening.

y



x

Multivariate analyse

Als er in totaal meer dan 2 variabelen zijn, meerdere features en 1 target, is er sprake van een multivariate analyse.


Bij 2 features wordt de formule dan:

$$y = a1 * X1 + a2 * X2 + b$$

En de formule bij 3 features is:

$$y = a1 * X1 + a2 * X2 + a3 * X3 + b$$

Elke feature krijgt dus zijn eigen slope (a), wel blijft er in totaal maar 1 intercept (b) bestaan. Dit kan gevisualiseerd worden in een 3D-tekening.



Om multivariate analyses te kunnen visualiseren mag je maximaal 2 features hebben

Ons menselijk oog kan namelijk slechts 3 dimensies zien.

Regressiemodellen evalueren: negatief => positief

We evalueren regressiemodellen door naar de afstanden te kijken tussen regressielijn enerzijds en werkelijke datapunten anderzijds

“Kan ik ‘gewoon’ deze afstanden optellen?”

Nee!

In dit voorbeeld zou onze totale errorwaarde $(-2 + 2) = 0$ zijn.


Maar... we hebben wel degelijk errors!
Simpelweg waarden bij elkaar optellen geeft dus een té positief beeld van het model.

Je wilt voorkomen dat positieve- en negatieve errors elkaar opheffen, daarom moet elke negatieve error een positieve worden.

2 veelgebruikte methoden:

- Kwadrateren: -2^2 wordt $+4$
- Elke negatieve waarde vermenigvuldigen met -1 .
 $-2 * -1$ wordt $+2$


Regressie-uitkomst



Evaluatiemetrieken

Testset

	Pclass	Fare	female	male	Age	Predicted_Age
1	1	26.55	True	False	58	61.0
12	3	8.05	False	True	20	47.0
13	3	31.275	False	True	39	46.0
14	3	78.542	True	False	14	42.0
15	2	16	True	False	55	20.0
16	3	29.125	False	True	2	46.0
17	2	13	False	True	36	50.0
18	3	18	True	False	31	62.0
19	3	7.225	True	False	36	20.0



“Wat is nou de algemene conclusie over de accuraatheid van mijn model?”

Mean Squared Error (MSE)

- Kwadrateer elke errorgrootte
- Bereken de som van alle kwadraten (Sum of Squared Errors => SSE)
- Bereken uit deze som het gemiddelde van alle kwadraten

Mean Absolute Error (MAE)

- Verander elke min-errorgrootte in een plus-errorgrootte (-1 -> 1, -3 -> 3, enzovoort).
- Bereken het gemiddelde van alle errorgroottes.

De derde evaluatiemetriek: de R^2 -score

De R^2 geeft weer hoeveel procent van de variatie in de afhankelijke variabele wordt verklaard door je model
Stel dat we in het model aantallen studie-uren gebruiken om aantallen studiepunten te voorspellen...


Volgens de linkeruitkomst (“high R^2 ”) worden verschillen in studiepunten in **hoge mate** verklaard door verschillen in studie-uren.

De R^2 zit dan in de “range” van 75-100%

Explained Variability - illustration



High R^2 - good explanation



Low R^2 - poor explanation

Volgens de rechteruitkomst (“low R^2 ”) worden verschillen in studiepunten **niet of nauwelijks** verklaard door verschillen in studie-uren.

De R^2 zit dan in de “range” van 0-25%

Demo time



Na vandaag...

Weet je...

Wat het verschil is tussen Machine Learning en “traditionele AI”

Wat het verschil is tussen supervised & unsupervised Machine Learning

Welke supervised modellen er zijn en wanneer je welke gebruikt.

Hoe het lineaire-regressiealgoritme werkt

Kan je...

Datasets prepareren voor het toepassen van Machine-Learningmodellen

Supervised regressiemodellen train- en testbaar maken.

De uitkomsten van regressiemodellen interpreteren en evalueren

HC + WC

