

Project Data Engineering - Criteria

	Design	Implementation
--	---------------	-----------------------

Source Data Modelling	• Alle relevante klassen en attributen zijn opgenomen. Weglatingen hieromtrent worden correct verantwoord tijdens het assessment. • De juiste database-overschrijdende associaties zijn gemodelleerd. Bijbehorende multipliciteiten zijn correct.*	• Per klasse is er een juiste CREATE TABLE opgesteld. Hierin zijn alle attributen, primaire- en vreemde sleutels opgenomen. • De datastructuur is aangemaakt met een SQL-script, waarin alle bovengenoemde CREATE TABLEs in de juiste volgorde staan. • De bovengenoemde datastructuur kan zowel gevuld worden met data als leeggehaald/gereset. Hierbij wordt er één inlaadstrategie consequent toegepast en verantwoord tijdens het assessment. In de code zitten weinig tot geen "code smells", zoals "code duplication". • Met één druk op de knop worden de bovengenoemde geautomatiseerde SDM-data-inlaadstappen uitgevoerd**. • Tijdens het assessment wordt de testprocedure goed doorlopen***.
-------------------------------------	---	---

Datawarehousing	• De juiste SDM-klassen zijn horizontaal en/of verticaal samengevoegd tot feiten en dimensies in een Sterschema. • Granulariteitsverschillen in de SDM-klassen worden correct afgehandeld in het Sterschema. Ook zijn hierin minimaal 3 afgeleide dimensie- en minimaal 3 afgeleide meetwaarden aangebracht. • Per Sterschema-klasse is een ETL-schema aangemaakt waarin de gewenste datastroom op de juiste manier wordt getekend én, waar nodig, beschreven.	• Per klasse is er een juiste CREATE TABLE opgesteld. Hierin zijn alle attributen, primaire- en vreemde sleutels opgenomen. • De datastructuur is aangemaakt met een SQL-script, waarin alle bovengenoemde CREATE TABLEs in de juiste volgorde staan. • Elk gemaakt ETL-schema is correct geïmplementeerd in Python. Hierbij wordt er één inlaadstrategie consequent toegepast en verantwoord tijdens het assessment. In de code zitten weinig tot geen "code smells", zoals "code duplication". • Minstens 2 dimensietabellen zijn correct geïmplementeerd als SCD-type 2, de rest als SCD-type 1. • Met één druk op de knop worden de bovengenoemde geautomatiseerde DWH-data-inlaadstappen uitgevoerd**. • Tijdens het assessment wordt de testprocedure goed doorlopen***.
-------------------------------	--	---

Dashboarding	n.v.t.	• Tijdens uitvoering van de datapijplijn worden logbestanden gevuld met de juiste data, ter indicatie van de pijplijnkwaliteit. In een Power-BI-dashboard**** wordt, volgens aan de hand van deze data de pijplijnkwaliteit visueel inzichtelijk gemaakt. • In een Power-BI-dashboard**** wordt met meerdere grafieken een oplossing geboden voor de betreffende drie knelpunten. Ook wordt er gebruik gemaakt van interactieve elementen (drill-downs, filters, enzovoort). Te alle tijde geldt: hoe vollediger een knelpunt wordt geanalyseerd en onderbouwd, hoe groter de kans is dat het werk op een hoger niveau wordt beoordeeld.
--------------	--------	--

***: Het vinden van database-overschrijdende associaties is in deze casus lastiger dan voorheen:**

- De naamgeving van tabellen die in meerdere databases voorkomen verschilt per database.
- De PK-invulling van tabellen die in meerdere databases voorkomen verschilt per database (in de ene database bevat de PK numerieke codes, in de andere database tekstuele id's, enzovoort).

****:** Binnen Great Outdoors heeft niet iedereen de kennis om Jupyter Notebooks uit te voeren. Je zult dus zelf op zoek moeten naar technische mogelijkheden om...

- Geschreven Notebooks om te zetten naar Pythonscripts.
- Pythonscripts te laten uitvoeren na één handmatige druk op de knop en/of eens per tijdseenheid (per kwartier, per uur, enzovoort) op automatische wijze.

*****:** De gegeven databases en CSV-bestanden van Great Outdoors bevatten data tot 1 oktober 2025. Tijdens het assessment worden er nieuwe versies van deze databronnen gegeven die aangevuld zijn met data ná 1 oktober 2025. Zo kun je dus, tijdens een zogenoemde testprocedure, het volgende demonstreren:

- **SDM:**
 - Nieuwe rijen uit operationele databases worden correct ingeladen.
 - Updates uit operationele databases worden correct overgenomen.
 - Verwijderingen uit operationele databases worden correct overgenomen in het SDM.
- **DWH (let op het verschil tussen SCD-typen 1 & 2):**
 - Nieuwe rijen uit het SDM worden correct ingeladen.
 - Updates uit het SDM worden correct overgenomen.
 - Verwijderingen uit het SDM worden correct overgenomen.

******:** heb je MacOS? Deze ondersteunt (helaas) geen Power BI! Overleg met je docent over het gebruik van alternatieven als QlikSense en/of Tableau. Hiermee wordt rekening gehouden in de beoordeling.